

基于深度学习的家庭电力消耗多变量时间序列预测

课程项目 PDF 报告

GitHub: <https://github.com/Mengtaigu111/jiqixuexi>

作者贡献与研究领域：本文由本人独立完成，主要贡献包括数据预处理、模型实现、实验设计、结果分析与报告撰写。研究领域为机器学习与时间序列预测。

实验结果来自 UCI Individual household electric power consumption 原始分钟级数据，已完成 LSTM、Transformer、HybridTCNTransformer、DMSAFormer 四种模型在 90 天和 365 天预测任务上的 5 个 seed 实验，共 40 次训练与评估。本文将 DMSAFormer 作为最终提出的改进模型，HybridTCNTransformer 作为中间改进模型和消融对照。

1. 问题介绍

家庭电力消耗预测可服务于智能家居、节能管理和智能电网调度。本项目使用过去 90 天多变量输入预测未来 90 天和 365 天 `global_active_power`。输入张量为 $[N, 90, 19]$ ，输出为 $[N, 90]$ 或 $[N, 365]$ 。输入变量包括全局有功功率、无功功率、电压、电流、分表能耗、天气变量和时间特征。模型均采用直接多步预测，评价指标为 MSE 与 MAE。

2. 模型

LSTM: 2 层 LSTM, hidden size=64, dropout=0.1, 最后隐状态接 MLP 输出未来曲线。

Transformer: d_model=64, 4 heads, 2 层 encoder, feed-forward=128, 正弦位置编码后 mean pooling 输出。

HybridTCNTransformer: 中间改进模型和消融对照; 1x1 Conv 投影到 64 通道, 3 个 kernel=3、dilation=1/2/4 的 TCN 残差块, 再接 TransformerEncoder。

DMSAFormer: 最终提出模型; 包含分解、多尺度卷积、变量注意力、Hybrid/LSTM 专家和 validation-calibrated expert 机制。所有校准参数仅在训练集划分出的 validation set 上估计, test set 只用于最终评估, 不参与模型选择、门控权重学习或 affine 校准。

3. 结果与分析

实验使用 input_len=90, output_len 分别为 90 和 365, seeds=2026,2027,2028,2029,2030, loss=MSELoss, optimizer=AdamW, learning rate=1e-3。全表比较中, DMSAFormer 在 90 天和 365 天任务上均取得最低 MSE 与 MAE。若只比较非 DMSAFormer baseline, 90 天任务 HybridTCNTransformer 最好, 365 天任务 LSTM 最好。90 天结果说明 TCN/CNN 有利于捕捉局部短期波动; 365 天结果说明小样本和季节漂移会使复杂模型更容易过拟合, 而 LSTM 更稳。DMSAFormer 的优势可能来自分解、多尺度卷积、变量注意力和专家校准的共同作用。

结果汇总表



90 天预测结果

Model	MSE mean $\pm$ std	MAE mean $\pm$ std	Runs
DMSAFormer	153907.02 $\pm$ 2207.87	301.13 $\pm$ 2.40	5
HybridTCNTransformer	155633.44 $\pm$ 3504.55	302.21 $\pm$ 2.73	5
Transformer	156632.34 $\pm$ 3657.48	305.30 $\pm$ 4.98	5
LSTM	163266.74 $\pm$ 1593.57	312.45 $\pm$ 2.17	5


365 天预测结果

Model	MSE mean $\pm$ std	MAE mean $\pm$ std	Runs
DMSAFormer	272821.28 $\pm$ 7078.78	409.59 $\pm$ 5.90	5
LSTM	316352.06 $\pm$ 16271.97	446.40 $\pm$ 12.26	5
HybridTCNTransformer	368574.75 $\pm$ 43798.41	491.58 $\pm$ 35.25	5
Transformer	442238.94 $\pm$ 45530.66	545.82 $\pm$ 32.61	5


MSE 指标对比




MAE 指标对比



90 天预测曲线对比



365 天预测曲线对比



4. 讨论

本项目已覆盖数据预处理、Dataset、四种模型、训练、评估、图表和汇总。真实数据存在缺失和噪声，预处理将 "?"、空字符串和非法数值转为 NaN；核心电力列使用前向/后向填充，不可恢复缺失会报错而不是直接补 0，并只在 train 集上拟合 scaler。Hybrid 在 90 天 baseline 中表现强，说明 TCN/CNN 有利于捕捉短期波动；LSTM 在 365 天 baseline 中表现强，说明小样本长期预测更需要稳定结构；Transformer 长期不稳可能来自样本少和预测跨度长。DMSAFormer 的 validation-calibrated expert 机制不使用 test 标签，因此不构成测试集信息泄漏。后续可加入更细粒度天气、节假日特征、概率预测、Informer/Autoformer/PatchTST、异常检测和不确定性估计。

参考文献：

[1] UCI Machine Learning Repository. Individual household electric power consumption Data Set.

[2] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.

[3] Vaswani, A., et al. (2017). Attention Is All You Need. *NeurIPS*.

[4] Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling.

[5] Wu, H., et al. (2021). Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting. *NeurIPS*.

[6] Zhou, H., et al. (2021). Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. *AAAI*.

[7] Nie, Y., et al. (2023). A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. *ICLR*.